


KOREA
ATOMIC
ENERGY
RESEARCH
INSTITUTE

2025년 12월 공개된 신규 모델

PeptiVerse 적용 가능성 검토 리포트

2026/03/09



더 나은 세상을 위한 원자력기술
국민과 세계가 지지하는

한국원자력연구원

CONTENTS

- 01 기존 예측 모델의 한계점과 도입 배경
- 02 PeptiVerse 핵심 아키텍처 분석
- 03 주요 지표별 예측 성능 검증
- 04 PeptiVerse 적용 가능성
- 05 부록



한국원자력연구원
Korea Atomic Energy Research Institute

KOREA
ATOMIC
ENERGY
RESEARCH
INSTITUTE

01

기존 예측 모델의 한계점과 도입 배경



PeptiVerse 연구 배경

Zhang et al. (2026)이 bioRxiv에 발표한 PeptiVerse는 다음과 같은 배경에서 시작되었습니다.



펩타이드 치료제의 독특한 위치

저분자 화합물과 항체의 장점을 결합하여 전통적으로 약물 개발이 어려웠던 단백질-단백질 상호작용(PPI) 표적에 접근 가능하며, 낮은 면역원성과 제조 복잡도를 제공합니다.



성공적인 약물 개발을 위한 다중 특성 최적화

결합 친화도(Binding Affinity)뿐만 아니라 용해도(Solubility), 투과성(Permeability), 독성(Toxicity), 혈중 반감기(Half-life) 등 다양한 개발 가능성(Developability) 특성의 동시 평가가 필수적입니다.



화학적 변형 펩타이드 수요 증가

비천연 아미노산(Non-canonical AA), 사이클화(Cyclization), PEGylation 등 화학적 변형 펩타이드의 증가로 천연 서열과 화학 구조를 모두 지원하는 범용 예측 플랫폼의 필요성이 대두되었습니다.

논문에서 언급한 선행연구의 한계

Zhang et al. (2026)은 기존 연구들의 다음과 같은 한계점을 언급했습니다.

서열 기반 예측기의 제한

Peptide-BERT 등은 천연 아미노산(Canonical AA)에만 국한되어 화학적 변형(비천연 AA, 사이클화 등)을 수용할 수 없다고 말했습니다.

소분자 ADMET 도구의 일반화 실패

저분자 약물(Drug-like molecules)로 훈련된 ADMET 플랫폼은 펩타이드/단백질의 고유한 화학 공간과 상이하여 정확한 예측이 어렵다고 설명했습니다.

구조 기반 지표의 낮은 상관성

AlphaFold3/OpenFold3의 ipTM 스코어는 펩타이드-단백질 결합 친화도와 거의 상관관계를 보이지 않는다고 보고했습니다 ($|r| \approx 0.05$).

통합 벤치마크 부재

아미노산 서열과 SMILES 표현을 모두 지원하는 체계적이고 포괄적인 펩타이드 특성 예측 플랫폼이 존재하지 않았다고 언급했습니다.

Peptide-BERT

서열 기반



천연 AA만

ADMET Tools

소분자 기반



도메인 차이

AlphaFold3

구조 기반



낮은 상관성

개별 도구들

특정 속성만



통합 불가

⚠ 통합적 예측 플랫폼 필요



한국원자력연구원
Korea Atomic Energy Research Institute

KOREA
ATOMIC
ENERGY
RESEARCH
INSTITUTE

02

PeptiVerse 핵심 아키텍처 분석



PeptiVerse의 핵심 Contribution



통합 입력 지원 (Unified Input Support)

아미노산 서열(Canonical sequences)과 화학적으로 변형된 SMILES 표현을 모두 지원하는 최초의 통합 치료용 펩타이드 특성 예측 플랫폼으로, 천연 및 비천연 펩타이드 모두를 평가할 수 있습니다.



광범위한 특성 예측 (Comprehensive Property Prediction)

용해도, 독성, 용혈성, 비오염성, 투과성, 혈중 반감기, 결합 친화도 등 치료용 펩타이드 개발에 필수적인 7가지 이상의 핵심 특성을 하나의 플랫폼에서 동시에 예측할 수 있습니다.



경량 예측 헤드로 SOTA 성능 달성


대규모 기반 모델(ESM-2, PeptideCLM)의 고정 임베딩과 다양한 머신러닝 헤드를 결합하여 (MLP, CNN, Transformer 등) 구조 예측보다 빠르고 정확한 State-of-the-Art 성능을 제공합니다.



재현성 및 접근성 (Reproducibility & Accessibility)

엄격하게 정제된 데이터셋, 유사도 기반 분할(Similarity-aware split)을 통한 일반화 성능 검증, 공개 웹 인터페이스(HuggingFace) 제공으로 연구자들이 손쉽게 활용할 수 있습니다.

PeptiVerse 아키텍처 Overview



* 결합 친화도 예측 시 필요

데이터 수집 및 큐레이션 전략



1단계: 데이터 소스 수집

DBAASP PepLand CycPeptMPDB ToxinPred3.0
SoluProtMutDB CAMP RCSB PDB DrugBank
PepTherDia PEPlife PROSO II THPdb2



2단계: 속성별 분류 및 통합

용혈성

용해도

비오염성

독성

투과성

반감기

결합 친화도



3단계: 품질 검증 및 정제

교차 대조: 다중 소스 검증 (예: DBAASP 재검증)

표준화: 단위 통일 (반감기 시간 변환)

중복 제거: Tanimoto 유사도, MMseqs2 클러스터링

품질 필터: 이상치 제거, 라벨 정규화



4단계: 최종 데이터셋

고품질 실험 검증 데이터

AA 서열 + SMILES 표현 동시 지원

Similarity-aware split 적용

다중 특성 통합 벤치마크

Encoder 및 Predictor



Encoder의 역할

펩타이드 서열/화학구조를 컴퓨터가 계산 가능한 수치 벡터로 변환합니다.



ESM-2 상세 (650M 파라미터, 약 2.5GB)

단백질 언어 모델: 수백만 개의 단백질 서열로 학습
 각 아미노산을 1280차원 벡터로 표현하며,
 서열 내 위치 정보, 구조적 특징, 기능적 신호를 모두 포함
 파라미터 고정(Frozen)으로 재학습 없이 지식 활용 → 빠르고 안정적



PeptideCLM (23M 파라미터)

SMILES 화학 구조를 이해하는 모델
 비천연 아미노산, 사이클화, 화학 변형을 모두 표현 가능하여 약물 개발을 위한
 화학적 변형 펩타이드 평가가 가능합니다.



Pooled vs Unpooled

Pooled: 전체 서열의 평균값 → 간단한 모델(XGBoost, SVM 등)에 적합
 Unpooled: 각 위치 정보 보존 → 상호작용 분석(Binding Affinity 등)에 중요



입력

AA 서열 / SMILES



ESM-2

650M / 2.5GB



PeptideCLM

23M 파라미터



임베딩 벡터

→ Predictor

Encoder 및 Predictor

속성별 선정 모델 (GitHub Best Model List 기반)

속성 (Property)	AA 입력 모델	SMILES 입력 모델
Hemolysis (용혈성)	SVM	Transformer
Non-Fouling (비오염성)	MLP	ENET
Solubility (용해도)	CNN	-
Permeability (Penetrance, 투과성)	SVM	-
Toxicity (독성)	-	Transformer
Binding Affinity (결합 친화도)	Cross-attention Transformer	Cross-attention Transformer
Permeability (PAMPA)	-	CNN
Permeability (CACO2)	-	SVR
Half-life (반감기)	Transformer	XGBoost

XGBoost

의사결정 나무들의 앙상블. 작은 데이터에 강함

SVM/SVR

데이터를 분류/예측하는 경계선 찾기. 노이즈에 강함

CNN

서열의 패턴(모티프)을 찾는 데 특화

MLP

기본적인 신경망. 빠르고 안정적

Transformer

서열 전체의 관계를 동시에 파악

ENET

선형 모델에 규제 추가. 단순하고 해석 가능

★ Cross-attention: 결합 친화도 예측의 핵심 기술

EX) 펩타이드의 Lys가 단백질의 Asp와 상호작용하는 것을 자동 감지하여 어떤 아미노산 쌍이 결합에 중요한지 학습



한국원자력연구원
Korea Atomic Energy Research Institute

KOREA
ATOMIC
ENERGY
RESEARCH
INSTITUTE

03

주요 지표별
예측 성능 검증



전체 성능 비교

분류 작업 (Classification Tasks)

속성 (Property)	입력 방식	F1 Score	데이터 수
Hemolysis (용혈성)	AA 서열	0.600	6,076개
	SMILES	0.520	6,076개
Solubility (용해도)	AA 서열	0.754	18,453개
	AA 서열	0.740	17,180개
Non-fouling (비오염성)	SMILES	0.736	17,180개
	AA 서열	0.929	2,324개
Permeability (Penetrance)	SMILES	0.845	11,036개

i 모든 수치는 Similarity-aware split 기반 검증 결과입니다. AA = 아미노산 서열, SMILES = 화학 구조 표현

전체 성능 비교


회귀 작업 (Regression Tasks)

속성 (Property)	입력 방식	Spearman ρ	데이터 수
Binding Affinity (결합 친화도)	AA 서열	0.557	1,436쌍
	SMILES	0.582	1,597쌍
Permeability (PAMPA)	SMILES	0.671	6,869개
Permeability (CACO2)	SMILES	0.550	606개
Half-life (반감기)	AA 서열	0.350	130개
	SMILES	0.300	245개

i 모든 수치는 Similarity-aware split 기반 검증 결과입니다. AA = 아미노산 서열, SMILES = 화학 구조 표현

Binding Affinity 상세

☰ Spearman 상관계수 (ρ) 비교



PeptiVerse (AA)

$$\rho = 0.557$$

아미노산 서열 입력 기준 $p < 0.001$

PeptiVerse (SMILES)

$$\rho = 0.582$$

화학 구조 기반 입력 $p < 0.001$

PepLand

$$\rho = 0.503$$

기존 baseline 모델

ESM-2

$$\rho = 0.452$$

단백질 언어 모델 기반

ⓘ 실험 결과 요약

- PeptiVerse는 아미노산 서열 입력 시 Spearman $\rho = 0.557$, SMILES 입력 시 $\rho = 0.582$ 의 상관계수를 기록했습니다.
- 기존 baseline 모델과 비교 시, PepLand는 $\rho = 0.503$, ESM-2는 $\rho = 0.452$ 를 보였습니다.
- 데이터 기반 예측 모델들은 모두 실험적 결합력과 양의 상관관계를 나타냈습니다.

Half-life 상세



데이터 규모

THPdb2, PEPLife, PepTherDia에서 수집한 데이터는 아미노산 서열 기반 130개, SMILES 기반 245개로 다른 속성(용해도 18,453개, 용혈성 6,076개)에 비해 제한적입니다.



데이터의 이질성 문제

실험 프로토콜이 서로 다르고, 측정값이 정성적("10분 이하") 또는 범위형("2-4시간")으로 보고된 경우가 많아 데이터의 질적 균일성이 부족합니다. 이는 전처리 과정에서 임의의 수치 변환이 필요했습니다.



예측 성능

반감기 예측의 Spearman 상관계수는 아미노산 입력 시 $\rho = 0.35$, SMILES 입력 시 $\rho = 0.30$ 으로, 결합 친화도(0.56~0.58)나 투과성(0.67) 대비 낮은 수준입니다.



한계사항

저자들은 "화학적 변형 펩타이드의 SMILES 기반 반감기 모델은 제한적이고 이질적인 실험 데이터로 인해 성능에 제약이 있다"고 명시했습니다.



한국원자력연구원
Korea Atomic Energy Research Institute

KOREA
ATOMIC
ENERGY
RESEARCH
INSTITUTE



04

PeptiVerse 적용 가능성

PeptiVerse 적용 가능성

가능한 기능

7가지 속성 동시 예측 가능
(용해도, 독성, 용혈성, 투과성, 결합력, 반감기 등)

아미노산 서열과 SMILES 표현 모두 지원

Binding Affinity 예측 시 표적 단백질 입력 지원

Apache 2.0 라이선스로 PeptiVerse 사용 코드 및
학습된 모델 가중치 제공 (내부 모델 구현 코드는 미공개)

시스템 요구사항

GPU 필수: CUDA 지원 6GB+ VRAM

ESM-2 모델: 약 2.5GB (650M 파라미터)

전체 환경 구성 시: 약 7.5GB (선택적 cuML 포함)

복잡한 의존성 (PyTorch, cuML, RDKit 등)

(출처: HuggingFace Repository - Full Setup 섹션)

적용 시 제약사항

웹 인터페이스는 단건 예측용, 공식 REST API 없음

대규모 배치 처리 기능 미지원

SSTR2 특이적 데이터 없음: 일반 펩타이드로만 훈련

Half-life 데이터 부족: AA 130개, SMILES 245개만

도메인 외 펩타이드 예측 시 성능 불확실



한국원자력연구원
Korea Atomic Energy Research Institute

KOREA ATOMIC ENERGY RESEARCH INSTITUTE



05

부록

REST API (Representational State Transfer API)

웹에서 프로그램끼리 데이터를 주고받는 표준 방식. 예: 웹 브라우저가 서버에 데이터 요청하는 것처럼 소프트웨어 간 통신을 가능하게 합니다.

GPU (Graphics Processing Unit)

그래픽 처리용 프로세서로, 수천 개의 계산을 동시에 수행할 수 있습니다. AI 모델 학습/추론에 필수적이며, CPU보다 10~100배 빠른 병렬 처리 능력을 제공합니다.

CUDA (Compute Unified Device Architecture)

NVIDIA GPU에서 과학 계산 및 AI 연산을 수행하게 해주는 소프트웨어 플랫폼. GPU 활용을 위한 필수 도구로, 대규모 데이터 처리를 가능하게 합니다.

VRAM (Video Random Access Memory)

GPU 전용 메모리로, 모델 가중치와 데이터를 GPU에서 처리할 때 사용합니다. 대형 AI 모델일수록 더 많은 VRAM이 필요합니다.

Apache 2.0 라이선스

출처 표시 조건으로 사용/수정/배포가 자유로운 오픈소스 라이선스. 상업적 사용이 가능하며, 소프트웨어를 자유롭게 활용할 수 있습니다.

머신러닝 모델 용어 해설

CNN (Convolutional Neural Network, 합성곱 신경망)

서열이나 이미지에서 국소적 패턴(모티프)을 찾는 데 특화된 신경망. 예: DNA 서열의 특정 모티프 인식과 유사합니다.

SVM (Support Vector Machine, 서포트 벡터 머신)

데이터를 구분하는 최적의 경계면을 찾는 분류/회귀 모델. 소량 데이터에서도 견고한 성능을 보이며 노이즈에 강합니다.

MLP (Multi-Layer Perceptron, 다층 퍼셉트론)

여러 층으로 구성된 기본형 신경망. 고정 길이 벡터 입력에 적합하며 빠르고 안정적입니다.

Transformer

자기주의(Attention) 메커니즘으로 서열 전체의 관계를 동시에 학습. 긴 서열에서 멀리 떨어진 잔기 간 상호작용 포착이 가능합니다.

XGBoost (Extreme Gradient Boosting)

여러 의사결정 나무를 결합한 앙상블 모델. 소규모/비선형 데이터에 강하며 빠른 학습이 가능합니다.

Cross-attention (교차 주의)

두 입력(펩타이드·단백질)이 서로의 중요한 위치를 보며 상호작용을 학습.
예: 어떤 펩타이드 잔기가 어떤 단백질 영역과 결합하는지 자동으로 파악합니다.

생화학/기술 용어 해설

SMILES (Simplified Molecular Input Line Entry System)

화학 구조를 텍스트로 표현하는 표기법.

예: "CC(=O)OC1=CC=CC=C1C(=O)O" = 아스피린

Peptide-BERT

펩타이드 서열 패턴 학습 AI 모델. 천연 아미노산만 지원, 화학적 변형 불가

ADMET

약물의 체내 동태: Absorption(흡수), Distribution(분포), Metabolism(대사), Excretion(배설), Toxicity(독성)

Pooled / Unpooled 임베딩

Pooled: 평균 벡터로 요약. Unpooled: 위치 정보 보존. 결합 예측은 Unpooled 사용

Frozen (고정)

사전 학습 모델 가중치를 재학습 없이 사용. 빠른 학습, 안정적 일반화

Spearman ρ (스피어만 상관계수)

순위 상관관계 측정 (-1~+1). 예측값과 실험값의 순위 일치도 평가

Tanimoto 유사도

화학 구조(분자 지문) 간 유사성 측정 지표 (0~1). SMILES 클러스터링에 사용

MMseqs2 클러스터링

서열 유사도 기반 빠른 클러스터링 도구. 아미노산 서열 데이터 분할에 사용

Similarity-aware split

유사한 서열이 train/test에 섞이지 않도록 클러스터 단위로 분할. 데이터 누출 방지

PAMPA (Parallel Artificial Membrane Permeability Assay)

인공 막을 이용한 투과성 측정법. $\log P_{\text{exp}} \geq -6.00$ 이면 높은 투과성

CACO2 (Caco-2 cell line)

인간 대장암 세포주. 장 흡수 및 약물 투과성 평가에 사용

F1 스코어

정밀도(Precision)와 재현율(Recall)의 조화 평균. 불균형 데이터 분류 성능 평가

용해도 (Solubility)

수용액에서 녹는 정도. 약물 전달 및 생체 이용률에 중요

독성 (Toxicity)

세포나 생체에 해로운 정도. ToxinPred3.0 등으로 예측

용혈성 (Hemolysis)

적혈구 파괴 정도. $HC50 < 100\mu M$ 이면 용혈성으로 분류

투과성 (Permeability)


세포막 통과 능력. 약물 흡수 및 생체 이용률 결정

결합 친화도 (Binding Affinity)

표적 단백질과의 결합 강도. K_d , K_i , $IC50$ 로 측정. 낮을수록 강한 결합

반감기 (Half-life)

혈청에서 농도가 절반으로 줄어드는 시간. 약물 지속 시간 결정



더 나은 세상을 위한 원자력기술
국민과 세계가 지지하는 한국원자력연구원



감사합니다.



한국원자력연구원
Korea Atomic Energy Research Institute